

HealthSearch — Motor de Busca Híbrido

Relatório Técnico de Recuperação de Informação e NLP

Instituição: UNIPÊ — Centro Universitário de João Pessoa	Professor: Me. Ricardo Roberto de Lima
Disciplina: Tendências em Ciência da Computação (RI / NLP)	Equipe: Mateus Ieno Ramalho, Heitor de Oliveira Mamede, João Gabriel Barreto de Araújo Falcão
	Auxílio: Gemini 3.1 pro

1. Arquitetura da Solução

A solução HealthSearch foi desenvolvida em Python e estruturada através do framework Streamlit para prover uma interface analítica interativa. O sistema endereça a problemática de 'pontos cegos' na recuperação de informações médicas unindo duas abordagens distintas de busca através de um pipeline em 4 fases principais mais re-ranking bônus:

- 1. Ingestão e Pré-processamento:** O sistema suporta tanto uma base local pré-carregada (6 diretrizes clínicas expandidas) quanto o upload de arquivos PDF (via pypdf). O texto passa por sanitização (remoção de caracteres especiais), normalização (minúsculas) e remoção de stopwords em português usando a biblioteca nltk.
- 2. Motor Léxico (BM25):** Utiliza-se a biblioteca rank_bm25 (Okapi BM25). Este motor é fundamental para capturar correspondências exatas de siglas, códigos médicos (ex: CÓD-ECG-12D) e jargões precisos. A interface permite calibrar dinamicamente a saturação da frequência (k_1) e a normalização de comprimento (b).
- 3. Motor Semântico Vetorial:** Emprega o modelo all-MiniLM-L6-v2 da biblioteca sentence-transformers para converter textos em embeddings densos. O ranqueamento é feito por Similaridade de Cosseno (utilizando util.cos_sim). Esta abordagem garante alta cobertura para sinônimos e intenções semânticas (ex: buscar por 'infarto' e recuperar 'isquemia miocárdica').
- 4. Algoritmo Híbrido (RRF):** A convergência é feita pelo método Reciprocal Rank Fusion. As posições geradas pelo BM25 e pelo Motor Semântico são fundidas sob a fórmula:
$$\text{Score_RRF} = \alpha \times [1 / (60 + \text{Rank_BM25})] + (1 - \alpha) \times [1 / (60 + \text{Rank_Semantico})]$$
- 5. Re-Ranking (Desafio Bônus):** Através de um Cross-Encoder (ms-marco-MiniLM-L-6-v2), os Top-3 resultados do pipeline híbrido são reavaliados por inferência conjunta, aprimorando a precisão final da relevância.

2. Comparação de Ranks (Gráfico / Tabela)

A eficiência do algoritmo híbrido (RRF) em suprir as deficiências individuais de cada motor pode ser observada na variação de ranks da Matriz Comparativa para a query "infarto":

ID Documento	Título	Rank BM25	Rank Semântico	Rank Final
Doc 2	Guia de Farmacologia Cardíaca	5	1	1 🏆
Doc 6	Procedimentos de UTI Geral	1	5	2
Doc 3	Diretriz de Hipertensão Arterial	4	2	3

Análise qualitativa: O BM25 costuma zerar o score (jogando o rank para baixo) se a palavra exata não estiver presente. O motor Semântico consegue identificar o contexto cardíaco e posicionar o Doc 2 adequadamente. O RRF resgata a performance unificada: o documento forte em ambas as abordagens lidera, seguido pelos documentos semanticamente relevantes.